

SISTEMATIZAÇÃO — MATEMÁTICA E ESTATÍSTICA PARA COMPUTAÇÃO

Laboratório Estatístico Interativo • Documento Oficial de Envio • Prof. Romes

1 IDENTIFICAÇÃO DA EQUIPE

Nome do Grupo:	DataBeats Analytics
Componente 1:	[Nome Completo do Aluno 1] — Matrícula: [000000001]
Componente 2:	[Nome Completo do Aluno 2] — Matrícula: [000000002]
Componente 3:	[Nome Completo do Aluno 3] — Matrícula: [000000003]
Componente 4:	[Nome Completo do Aluno 4] — Matrícula: [000000004] (opcional)
Componente 5:	[Nome Completo do Aluno 5] — Matrícula: [000000005] (opcional)

2, 3 e 4 LINKS OFICIAIS DE ENTREGA (TESTADOS EM GUIA ANÔNIMA)

2 Link dos Dados Crus:	https://raw.githubusercontent.com/.../spotify_songs.csv (TidyTuesday/Kaggle)
3 Repositório da Solução:	https://github.com/seu-usuario/laboratorio-estatistico (GitHub Público c/ código, README e RELATORIO.md)
4 Vídeo de Demonstração:	https://youtu.be/SEU_LINK_AQUI (Vídeo de 3 a 5 min Não Listado no YouTube ou Drive Aberto)

5 RESUMO EXECUTIVO DA SOLUÇÃO

Dataset Selecionado: *Spotify Tracks Dataset* com **32.833 registros reais** e 23 variáveis coletadas via API oficial. Contém 8 variáveis numéricas contínuas (dançabilidade, energia, volume em dB, valência, tempo em BPM, duração, acústica, fala) e atributos categóricos (6 gêneros principais e 24 subgêneros). Supera em mais de 32 vezes o piso de 1.000 registros do Módulo 0.

Arquitetura e Módulos Implementados:

- **Módulo 1 (Núcleo Próprio):** Biblioteca *minhastats.py* implementada 100% autoral em Python puro (sem NumPy/SciPy/statistics para os cálculos). Calcula média, mediana, modas, amplitude, variâncias e desvios padrão (amostral com $n-1$ e populacional com N), percentis com interpolação linear, quartis, IQR, CV, covariância, Pearson e Mínimos Quadrados OLS. Validada com **27 testes automatizados no PyTest** (tolerâncias $rtol=1e-7$, $atol=1e-9$).
- **Módulo 2 (Estatística Descritiva Interativa):** Tabela de frequências com classes pela Regra de Sturges, histograma, boxplot, detecção de outliers pelo método 1.5-IQR e interpretação automática de assimetria de Pearson.
- **Módulo 3 (Probabilidade & Simulação Monte Carlo):** Comprovação da Lei dos Grandes Números (convergência estocástica para $E[X]$) e do Teorema Central do Limite (sorteando durações de músicas e demonstrando convergência empírica para a Normal $N(\mu, \sigma/\sqrt{n})$).
- **Módulo 4 (Distribuições Teóricas):** Sobreposição de curvas Normal, Exponencial e Uniforme sobre histograma e análise por Q-Q Plot.
- **Módulo 5 (Regressão Linear Simples):** Mínimos Quadrados OLS próprios com reta ajustada, R^2 (45,9%), erro padrão, calculadora interativa de predição e alerta categórico de que *correlação não implica causalidade*.


As 3 Principais Descobertas Estatísticas (Módulo 6):

1. **A 'Guerra do Volume' (Loudness War) e a Relação com Energia:** Constatou-se correlação linear positiva muito forte ($r = +0,6774$, $R^2 = 45,88\%$) entre volume e energia. A distribuição de volume apresenta assimetria negativa acentuada ($As = -0,31$), com **mediana em -6,17 dB** e mais de 75% das faixas comprimidas entre -9 dB e -4 dB, comprovando a prática industrial de hiper-compressão dinâmica para elevar o impacto perceptivo.
2. **A Lei da Duração Musical no Streaming e Outliers Superiores:** Média de duração de 225,8s (~3min 46s) versus mediana de 216,0s (~3min 36s), com assimetria positiva expressiva. A regra do IQR detectou **1.637 faixas atípicas (4,99%)** exclusivamente na cauda superior ($> 325,1s$). Isso traduz o modelo econômico do streaming (monetização a partir de 30s incentiva composições enxutas de ~3 minutos), ficando músicas longas restritas a versões estendidas de música eletrônica (EDM) e rock progressivo.
3. **A Bimodalidade Oculta da Popularidade (Efeito 'Catálogo Morto'):** Descobriu-se que **2.703 músicas (8,23% da base)** possuem popularidade exatamente igual a zero. Ao isolar as faixas ativas (popularidade > 0), a distribuição assume comportamento simétrico e quase normal em torno da média de 46,2 pontos. Esse padrão revela a estrutura de Cauda Longa das plataformas: milhões de faixas nunca superam a barreira algorítmica inicial.

PAINEL DE EVIDÊNCIAS GRÁFICAS E VALIDAÇÃO NUMÉRICA


Comprovação Visual e Testes de Precisão do Núcleo Próprio

Evidências Gráficas Geradas pela Aplicação:



Módulo 2: Histograma e Boxplot com detecção IQR.

Módulo 3: Simulação TCL convergindo para a Normal.



Módulo 5: Diagrama de Dispersão e Reta de Regressão Linear Simples OLS com $R^2 = 45,9\%$.

Validação Automatizada Cruzada do Núcleo minhastats.py (27 Testes no PyTest):

Função Implementada	Referência Validada	Tolerância Numérica	Diferença	Status
media(valores)	numpy.mean / statistics.mean	rtol=1e-7, atol=1e-9	0.000000e+00	■ APROVADO
mediana(valores)	numpy.median / statistics.median	rtol=1e-7, atol=1e-9	0.000000e+00	■ APROVADO
moda(valores)	statistics.multimode (unimodal/multimodal)	Exato em inteiros/floats	0.000000e+00	■ APROVADO
amplitude(valores)	numpy.ptp (max - min)	rtol=1e-7, atol=1e-9	0.000000e+00	■ APROVADO
variancia(valores, tipo)	numpy.var (ddof=1 amostral / ddof=0 pop)	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO
desvio_padrao(valores, tipo)	numpy.std (ddof=1 amostral / ddof=0 pop)	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO
percentil(valores, p)	numpy.percentile (method='linear')	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO
quartis(valores)	numpy.percentile(p=[25, 50, 75])	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO
coeficiente_variacao(valores)	Manual / SciPy variation	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO
covariancia(x, y, tipo)	numpy.cov (ddof=1 e ddof=0)	rtol=1e-7, atol=1e-9	< 1.000e-11	■ APROVADO
correlacao_pearson(x, y)	scipy.stats.pearsonr	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO
regressao_linear_simples(x, y)	scipy.stats.linregress (slope, intercept, r, r2)	rtol=1e-7, atol=1e-9	< 1.000e-12	■ APROVADO