

Sistematização — Laboratório Estatístico Interativo

Matemática e Estatística para Computação · Prof. Romes Heriberto
Análise e Desenvolvimento de Sistemas — EAD, Campus Virtual · 2º semestre de 2026

1. Identificação

Nome do grupo	DataBeats Analytics
Modalidade	Entrega individual
Componente	Isac Salatiel — Matrícula: 72650219

2. Link dos dados crus

Spotify Songs Dataset — TidyTuesday / Kaggle, coletado via API oficial do Spotify (pacote *spotifyr*). 32.833 registros e 23 variáveis.

https://raw.githubusercontent.com/rfordatascience/tidytuesday/master/data/2020/2020-01-21/spotify_songs.csv

3. Link da solução

Repositório público com código-fonte, README.md, RELATORIO.md e testes automatizados:

<https://github.com/Zackzinzz07/laboratorio-estatistico>

4. Vídeo de demonstração

O vídeo de demonstração não acompanha esta entrega. O autor comunicou a situação diretamente ao docente. Toda a aplicação, o núcleo estatístico e os testes automatizados estão disponíveis e executáveis a partir do repositório indicado no item 3, com instruções de instalação e execução no README.md.

5. Resumo Executivo

Dataset escolhido

O **Spotify Songs Dataset** reúne 32.833 faixas com atributos sonoros medidos pela API do Spotify — 32 vezes o mínimo de 1.000 registros exigido, o que garante validade assintótica às simulações da LGN e do TCL. São 9 variáveis numéricas (*danceability*, *energy*, *loudness*, *valence*, *tempo*, *duration_s*, *track_popularity*, *acousticness*, *speechiness*) e 3 categóricas (*playlist_genre*, 6 classes; *playlist_subgenre*, 24; *mode*). As formas distribucionais são variadas — de aproximadamente normais (*tempo*) a fortemente assimétricas com cauda longa (*duration_s*) —, permitindo exercitar probabilidade e regressão em dados reais.

Módulos implementados

- **Módulo 0 — Dados reais:** carga, dicionário de variáveis e metadados das 32.833 faixas.
- **Módulo 1 — Núcleo próprio:** `minhastats.py` com 17 funções escritas do zero usando só `math` e tipos nativos — média, mediana, moda, amplitude, variância e desvio padrão (amostral e populacional), percentis, quartis, CV, covariância, Pearson, mínimos quadrados, outliers por IQR, frequências por Sturges e assimetria. Validado por 27 testes em `pytest` contra `NumPy`, `SciPy` e `statistics` (`rtol = 1e-7`, `atol = 1e-9`).
- **Módulo 2 — Descritiva interativa:** tabela de frequências, medidas de centro e dispersão, histograma, boxplot, outliers pela regra de Tukey (1,5·IQR) e interpretação textual automática de assimetria.
- **Módulo 3 — Monte Carlo:** Lei dos Grandes Números (até 10.000 ensaios) e Teorema Central do Limite sobre *duration_s*, com controle de repetições e tamanho da amostra.
- **Módulo 4 — Distribuições teóricas:** curvas Normal, Exponencial e Uniforme com parâmetros estimados dos dados, mais gráfico Q-Q para discussão da aderência.
- **Módulo 5 — Correlação e regressão:** dispersão, reta OLS do núcleo próprio, equação, R^2 , erro padrão, predição interativa e alerta sobre causalidade.
- **Módulo 6 — Descobertas:** as três sínteses apresentadas a seguir.

As 3 principais descobertas

1. A "Loudness War" é mensurável nos dados

Loudness e *energy* correlacionam-se em $r = +0,6774$ ($R^2 = 45,88\%$). A mediana de volume é **-6,17 dB** com assimetria negativa ($As = -0,31$): mais de 75% das faixas ficam comprimidas entre -9 dB e -4 dB, padrão consistente com a compressão dinâmica praticada pela indústria. *Limite*: associação, não causalidade — o gênero é confundidor plausível.

2. A duração convergiu para a janela do streaming

Média de 225,8 s contra mediana de 216,0 s ($As = +0,49$). O IQR apontou 1.637 outliers (4,99%), **todos** na cauda superior ($> 325,1$ s) e nenhum na inferior. O acervo se concentra entre 3 e 3,5 min, compatível com o *stream* monetizável a partir de 30 s; os atípicos são remixes estendidos e rock progressivo.

3. A popularidade esconde uma bimodalidade ("catálogo morto")

2.703 faixas (8,23%) têm popularidade exatamente zero, formando um pico isolado à esquerda. Removendo esse grupo, a distribuição vira praticamente unimodal e simétrica (média 46,2, mediana 47,0). É a cauda longa das plataformas: uma regressão linear ingênua sobre a popularidade contamina os resíduos — o caso pede um modelo *hurdle* ou *zero-inflated*.